

k近傍法

正田 備也

masada@rikkyo.ac.jp

spam



例題: スパムフィルタ

- メールがスパムか否かを判定するシステムを作りたい
- 設定：
 - ある程度の数のメールを、すでに持っている。
 - 全てのメールに「スパム」か「通常」かのラベルが付けられている。
 - このラベルをうまく使って、新しく来たメールについて、スパムか否かを判定したい。

素朴な手法

- 新しく来たメールと全く同じメールが、すでに持っているメールの中にないか、探す
- もしあれば、そのメールと同じラベルを答えとして出力する

問

- 前スライドの手法の問題点は何か

instance-based vs model-based


- 機械学習にはinstance-basedな手法とmodel-basedな手法がある
- 先ほどの手法はinstance-basedな手法
 - すでに持っているメール = 実例(instance)をそのまま使うから。
- とはいえ、前のスライドで考えたとおり、問題がある

類似性に基づく instance-based method

- 同じメールが見つからなくても、似ているメールはあるだろう
- 新しく来たメールと似ているメールがあるなら、それと同じラベルを答えとして出力すれば良いのでは？
- 問：メールが似ているとは、どういうことか？

問

- 2通のメールが似ているか似ていないかを調べる手法を、考えてください（5分待ちます）
- 計算機に実行させることができる手法でないと、ダメです。
- スпамか否かの判定に役立つ手法でないと、ダメです。




類似度の例

- 例えば、2つのメールに共通して出現する単語の数を数えて、それが多いほど似ている、とする
- 他にどんな類似度の尺度が考えられるか？



This is
the first
mail.



Is this the
first
mail?



This is
the
second
mail.

k近傍法

k-nearest neighbor

k近傍法 (k-Nearest Neighbors)

- 新しく得られたinstanceについて、
- すでに正解が分かっているinstancesの中から、それと最も類似しているものをk個選び、
- それらk個の正解を利用して予測を実現する手法

予測問題の二種類

1. クラスの予測

2. 数値の予測

クラスの予測 = 分類(classification)

- 分類 (classification)

- 未知のinstanceを、複数のクラスのいずれかへグループ分け
- その際、グループ分けがすでに済んでいるデータを利用する
 - グループ分けが済んでいる = 正解が分かっている
 - 正解がすでに分かっているデータを「訓練データ(training data)」と呼ぶ
- 例：スパムフィルタ、手書き数字認識、など

数値の予測 = 回帰(regression)

- 回帰(regression)
 - 未知のinstanceについて、関心がある数値(target value)を予測
 - その際、target valueがすでに分かっているinstancesを利用する
 - target valueが分かっている = 正解が分かっている
 - 正解がすでに分かっているデータを「訓練データ(training data)」と呼ぶ
 - 例：住宅価格の予測、CTRの予測、など

k近傍法のk

- k近傍法では、最も似ているk個を選ぶ
 - 分類：k個で多数決をとる
 - 回帰：k個のtarget valueの平均をとる
- 個数kは調整する必要あり
 - 予測性能ができるだけ良くなるようにkを選ぶ

類似度をどう決めるか

「メールとメールの間に、
どのような類似度を定義すれば、
スパムフィルタのシステムに有用か？」

近傍 = 似ているもの

- k近傍法においては、**instance**間の類似度を、うまく決める必要がある
 - スпамフィルタ：二つのメールが似ている、とは？
 - 似ているメールは、クラスが同じになるように。
 - 住宅価格予測：二つの住宅が似ている、とは？
 - 似ている住宅は、価格が近くなるように。

例題: 生活満足度を予測する

- 参考書のp.19にある例
 - https://github.com/ageron/handson-ml3/blob/main/01_the_machine_learning_landscape.ipynb
 - [Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd Edition](#)
- Claudeさんの協力のもと、新しくデータセットを作りました
 - [life_satisfaction_2010_2024.csv](#)
 - Canvas LMSの「ファイル」→「プランナークラス」にも置いてあります。