

ロジスティック回帰

機械学習演習 プランナークラス

masada@rikkyo.ac.jp

予測問題の二種類

- 回帰(regression)=数値の予測
- 分類(classification)=クラスのパredict
• 今回からこちら

ロジスティック回帰による2値分類

- ロジスティック回帰は回帰=値の予測
- だが、ロジスティック回帰が予測するのは、値は値でも確率
 - 確率とは0から1の範囲におさまる値
 - この確率を、2つのクラスのうち的一方に属する確率として使う
- だから、ロジスティック回帰は2値分類に使える
 - (もう一方のクラスに属する確率) = $1 - (\text{一方のクラスに属する確率})$

ロジスティック回帰におけるクラス予測

- ターゲットの値の範囲
 - 線形回帰: $-\infty$ から $+\infty$ まで
 - ロジスティック回帰: 1か0
 - 一方のクラスに属するか属さないかの2値
- ロジスティック回帰における予測
 - この1か0かの2値を「コイン投げ」で予測する

「コイン投げ」による予測

- 確率 p_i で表が出るコインを投げてターゲット y_i を作る
 - ターゲットの値1がコインの表に、値0がコインの裏に、それぞれ対応
- 確率 p_i は以下のように計算する

$$p_i = \frac{1}{1 + e^{-(a_0 + a_1 x_{i,1} + \dots + a_d x_{i,d})}}$$


シグモイド関数

- シグモイド関数の式

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$

- 確率 p_i は以下のように書ける

$$p_i = \sigma(a_0 + a_1 x_{i,1} + \cdots + a_d x_{i,d})$$



ロジスティック回帰の予測モデル

$$p_i = \frac{1}{1 + e^{-(a_0 + a_1 x_{i,1} + \dots + a_d x_{i,d})}}$$



$$\log\left(\frac{p_i}{1 - p_i}\right) = a_0 + a_1 x_{i,1} + \dots + a_d x_{i,d}$$

ロジスティック回帰と線形回帰の違い

- 線形回帰と比べると予測モデルを表現する式の左辺が違う

$$\log \left(\frac{p_i}{1 - p_i} \right) = a_0 + a_1 x_{i,1} + \cdots + a_d x_{i,d}$$

- 線形回帰では $a_0 + a_1 x_{i,1} + \cdots + a_d x_{i,d}$ が そのまま 予測値になる
- p_i は i 番目のデータ点 x_i が一方のクラスに属する確率
- 左辺の関数はlogitと呼ばれる関数
 - それぞれのクラスに属する確率の比の対数。

ロジスティック回帰におけるパラメータ推定

- 確率 p_i で表が出るコインを投げてターゲット y_i を作る
 - ターゲットの値1がコインの表に、値0がコインの裏に、それぞれ対応

$$p_i = \frac{1}{1 + e^{-(a_0 + a_1 x_{i,1} + \dots + a_d x_{i,d})}}$$

- パラメータ推定の方法
 - 訓練データのターゲット y_i の全て($i = 1, \dots, N$)が、このコイン投げによって作られる確率を、できるだけ大きくするように、パラメータ $a_0, a_1, \dots, a_d$ の値を求める。

線形回帰におけるパラメータ推定

- ターゲット y_i は、 $a_0 + a_1x_{i,1} + \dots + a_dx_{i,d}$ を平均とする正規分布に従うと考える
 - ロジスティック回帰と違って $a_0 + a_1x_{i,1} + \dots + a_dx_{i,d}$ をそのまま使う
- パラメータ推定の方法
 - 訓練データのターゲット y_i の全て($i = 1, \dots, N$)が、この正規分布から作られる確率を、できるだけ大きくするように、パラメータ $a_0, a_1, \dots, a_d$ の値を求める。

ターゲットが作られる確率

- 場合分けして考えると...

- ターゲットが $y_i = 1$ のとき、このターゲットが作られる確率は p_i
- ターゲットが $y_i = 0$ のとき、このターゲットが作られる確率は $1 - p_i$

- 両方の場合をまとめて書くと...

$$p_i^{y_i}(1 - p_i)^{(1-y_i)}$$

- 全てのインスタンスの確率は...

$$\prod_{i=1}^N p_i^{y_i}(1 - p_i)^{(1-y_i)}$$

ロジスティック回帰の損失関数

log loss (binary cross entropy)

$$L(a_0, a_1, \dots, a_d) = - \sum_{i=1}^N \{y_i \log p_i + (1 - y_i) \log(1 - p_i)\}$$

ただし

$$p_i = \frac{1}{1 + e^{-(a_0 + a_1 x_{i,1} + \dots + a_d x_{i,d})}}$$

一般化線形モデル

- 一般化線形モデルの部品

1. 線形予測子

- $a_0 + a_1x_{i,1} + \dots + a_dx_{i,d}$ のこと。

2. リンク関数

- 線形回帰では恒等関数、ロジスティック回帰ではlogit

3. 確率分布

- 線形回帰では正規分布、ロジスティック回帰ではベルヌーイ分布

- 参考資料: <https://kuboweb.github.io/-kubo/stat/2018/Ees/c/HOkubostat2018c.pdf>

言語モデルのnext token prediction

- 言語モデルの部品

1. Transformerモデル

- 語彙サイズに等しい次元のベクトル
 - 単独の数値を出力するモデルを複数同時に使うイメージ。

2. リンク関数の逆関数 (ロジスティック回帰のシグモイド関数) に当たるもの

- softmax関数

3. 確率分布

- カテゴリカル分布 (マルチヌーイ分布)

損失関数の勾配の計算


$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\frac{d}{dx} \sigma(x) = - \frac{e^{-x}}{(1 + e^{-x})^2} = \frac{e^{-x}}{(1 + e^{-x})^2}$$

$$= \frac{1}{1 + e^{-x}} \left(1 - \frac{1}{1 + e^{-x}} \right) = \sigma(x)(1 - \sigma(x))$$

関数の値そのものを使って簡単に書ける!

$x = 0$ での接線の傾きは
 $\sigma(0)(1 - \sigma(0))$
 $= 0.5(1 - 0.5) = 0.25$



$x = 2$ での接線の傾き
 $\sigma(2)(1 - \sigma(2))$
 $= 0.881(1 - 0.881)$
 $= 0.105$