

dimensionality reduction


機械学習演習 プランナークラス

masada@rikkyo.ac.jp

PCAで計画行列をless noisyにする

$$\begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,d} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{i,1} & x_{i,2} & \cdots & x_{i,d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N,1} & x_{N,2} & \cdots & x_{N,d} \end{bmatrix}$$


左辺は
元々の
計画行列



$\div$



$\cdot$



右辺のほうが
less noisyに
なっている

PCAの考え方


- 高次元空間に散らばったデータ点の集合が与えられている
 - データ点はベクトルです(原点から発してその点まで達する矢印のイメージ)
 - データの重心が原点になるように、全体の位置をシフトさせておく。
- データ点が最も広く散らばっている方向を見つける
 - この方向を表すベクトルが、主成分
- その方向と直交する超平面上に、全てのデータ点を押しつぶす
 - データ点の散らばっている空間の次元が、ひとつだけ下がる
- 次元を下げた空間で、また同じことをする
 - つまり、データ点が最も広く散らばっている方向を見つける


「最も広く散らばっている方向」

- 式で書くと以下の通り

$$\mathbf{w}_1 = \arg \max_{\|\mathbf{w}\|=1} \|\mathbf{X}\mathbf{w}\|^2$$

- $\mathbf{X}$ は計画行列（ただし重心を原点へ移動した後のもの）
- $\mathbf{X}\mathbf{w}$ は列ベクトル
 - $\mathbf{X}$ の各行ベクトル $\mathbf{x}_i$ と $\mathbf{w}$ との内積の値が要素として並ぶ、列ベクトル。
 - この内積の値は、 $\mathbf{X}$ の各行ベクトル $\mathbf{x}_i$ の、 $\mathbf{w}$ の方向への座標値。
 - つまり、 $\mathbf{w}$ の方向への+か-の符号がついた長さ





Xw のイメージ

各データ点 x_i と w との内積 $x_i^T w$ を、まとめて書いているだけ。


「データ点を押しつぶす」

- 式で書くと以下の通り

$$\hat{X} = X - (Xw_1)w_1^T$$

- Xw は列ベクトル


- X の各行ベクトル x_i と w との内積の値が要素として並ぶ、列ベクトル。
- この内積の値は、 X の各行ベクトル x_i の、 w の方向への座標値。
- その座標値に w_1 をかけて、元の X の行ベクトル x_i から引いている。
- こうすると、 x_i から w_1 方向の成分を消せる。
- つまり、 x_i を、 w_1 と直交し原点を通る超平面上へ押しつぶしている。




PCAの（実際の）アルゴリズム

1. データを中心化する（平均を引く）
 2. 共分散行列 $\mathbf{C} = \frac{1}{n-1} \mathbf{X}^T \mathbf{X}$ を計算する
 3. 共分散行列 $\mathbf{C}$ の固有値と固有ベクトルを求める
 4. 最も大きい m 個の固有値に対応する固有ベクトルを選ぶ
- このアルゴリズムで求まる固有ベクトルと、「最も広く散らばった方向」が同じになることは、ちゃんと証明できる
 - 等式制約の場合のラグランジュ未定乗数法を使う。

PCAによる次元圧縮(1/2)




PCAによる次元圧縮(1/2)



PCA, NMF, PLSIなど

- 計画行列を、小さい2つの行列の積で表現し直す



NMF (Nonnegative Matrix Factorization)

- PCAの問題点

- 元々どの属性値も負の値を取り得ないデータには適用しにくい
- 主成分は負の値を含みうるが、このような負の値は解釈が難しい

- NMFの特徴

- PCAでいう主成分に相当するベクトルが非負ベクトルとして得られる
- 得られる非負ベクトルは、お互いに直交しないこともありうる
 - ただし、疎なベクトルになるので、ほぼ直交しているともみなせる。
 - 参考: <https://www.cs.cmu.edu/~changbo/publications/IJPRAI05.pdf>

PLSI (probabilistic latent semantic indexing)

- NMFの確率モデル版
- 詳細は秋学期の「統計モデリングI」で
- EMアルゴリズムでモデル・パラメータを推定する

LDA (latent Dirichlet allocation)

- PLSIをベイズ化した確率モデル
- 詳細は来年度夏学期の「統計モデリング2」で
- 変分推論(variational inference)で事後分布のパラメータを推定する
- ただし、今であれば、言語モデルでテキストを埋め込んでクラスタリングで分析する方が、もっと興味深い結果が得られる。