

カーネルトリック入門

特徴空間への写像を陽に計算せず、内積だけで高次元の力を借りる

立教大学大学院 人工知能科学研究科

SVM と k-means への応用を含む

SECTION 01

なぜカーネルが必要か

多くの機械学習アルゴリズムは、本質的に**線形**な仮定を持っています。線形分類器は超平面でデータを分け、k-means は線形空間上のユークリッド距離で重心を求めます。しかし現実のデータは、しばしば**線形では分離**できない複雑な構造を持っています。




図1：XOR的なパターンは線形分類器では分離できない

この問題への古典的な解決策は「データを**高次元空間に写像**し、その空間で線形モデルを適用する」というものです。しかしナイーブに高次元ベクトルを計算すると、計算コストが爆発します。**カーネルトリック**はその計算を回避するエレガントな方法です。

SECTION 02

特徴写像 ϕ とは

元のデータ空間 $\mathcal{X} \subseteq \mathbb{R}^d$ から、より高次元（場合によっては無限次元）の**特徴空間 $\mathcal{H}$** への写像を

定義：特徴写像

$$\phi: \mathcal{X} \rightarrow \mathcal{H}$$

$\mathcal{H}$ は内積空間（ヒルベルト空間）。 $\phi(\mathbf{x})$ は元のデータ点 $\mathbf{x}$ を特徴空間に写した「特徴ベクトル」。

具体例：2次元 $\rightarrow$ 5次元

$\mathbf{x} = (x_1, x_2) \in \mathbb{R}^2$ に対して、2次の多項式特徴写像を考えます。

例：2次多項式特徴写像

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1^2, x_1x_2, x_2^2) \in \mathbb{R}^6$$

⚠ 計算コストの問題

元の特徴量が d 次元のとき、 p 次の多項式特徴写像の次元数は $\binom{d+p}{p}$ となります。

例： $d = 100$, $p = 2$ では **5,151 次元**。 $p = 3$ では **176,851 次元**。

この高次元ベクトルを陽に計算・保存することは、多くの場合非現実的です。




図2：特徴写像 ϕ によって非線形問題を線形問題に変換する

特徴写像 ϕ を明示的に計算する代わりに、**2点間の内積**を直接計算する関数を **カーネル関数**と呼びます。

定義：カーネル関数

$$k(\mathbf{x}, \mathbf{x}') = \langle \phi(\mathbf{x}), \phi(\mathbf{x}') \rangle_{\mathcal{H}}$$

$k: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ は、特徴空間での内積を元の空間の点の対から計算する。

多項式カーネルの例で確かめる

$\mathbf{x} = (x_1, x_2)$, $\mathbf{x}' = (x'_1, x'_2)$ として、 $k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^\top \mathbf{x}')^2$ を展開してみましょう。

$$\begin{aligned} k(\mathbf{x}, \mathbf{x}') &= (x_1 x'_1 + x_2 x'_2)^2 \\ &= x_1^2 x_1'^2 + 2x_1 x_2 x'_1 x'_2 + x_2^2 x_2'^2 \\ &= \langle (x_1^2, \sqrt{2}x_1 x_2, x_2^2), (x_1'^2, \sqrt{2}x'_1 x'_2, x_2'^2) \rangle \end{aligned}$$

これはちょうど $\phi(\mathbf{x}) = (x_1^2, \sqrt{2}x_1 x_2, x_2^2)$ という特徴写像の内積に一致しています！

✓ ポイント

カーネル関数 $k(\mathbf{x}, \mathbf{x}')$ を計算することは、特徴ベクトル $\phi(\mathbf{x})$ と $\phi(\mathbf{x}')$ を陽に作ってから内積を取ることに等しい。しかし、元空間での計算量はわずか $O(d)$ ！

Mercer の定理（カーネルが有効な条件）

すべての関数がカーネル関数になれるわけではありません。有効なカーネルであるための条件は次のとおりです。

MERCER の定理（概要）

対称関数 $k(\mathbf{x}, \mathbf{x}')$ が有効なカーネルである $\Leftrightarrow$ 任意の有限個の点 $\{\mathbf{x}_i\}$ に対するグラム行列

$$K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$$

が**半正定値**（positive semi-definite, PSD）である。

🔑 グラム行列とは

データ点 $\mathbf{x}_1, \dots, \mathbf{x}_n$ に対して、すべてのペアのカーネル値を並べた $n \times n$ 行列 K を**グラム行列**（**カーネル行列**）と呼びます。

アルゴリズムの実装では、この行列を一度計算してしまえば、後の計算はすべてこの行列を通じて行われます。

SECTION 04

カーネルトリック

アルゴリズムが $\phi(\mathbf{x})$ だけでなく、内積 $\langle \phi(\mathbf{x}), \phi(\mathbf{x}') \rangle$ の形でしか使わないなら、 ϕ を知らなくてもよい。

多くの機械学習アルゴリズムは、その核心部分においてデータ点を**内積**の形でしか参照しません。もしアルゴリズム中のすべての内積 $\langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$ をカーネル関数 $k(\mathbf{x}_i, \mathbf{x}_j)$ で置き換えられるなら、特徴ベクトルを陽に計算せずに済みます。これが**カーネルトリック**です。

🔑 カーネルトリックの骨格

- 1 元のアルゴリズムを内積だけを使う形に書き直す（**双対表現**）。
- 2 すべての内積 $\langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$ を $k(\mathbf{x}_i, \mathbf{x}_j)$ で置き換える。
- 3 グラム行列 K を使ってアルゴリズムを実行する。
- 4 （無限次元の特徴空間でも）計算コストは $O(n^2)$ 程度に抑えられる。

計算コストの比較


アプローチ	特徴ベクトルの次元	内積1回の計算コスト	特徴マップの明示
特徴写像を直接使う	D （非常に大きい）	$O(D)$	必要
カーネルトリック	—（計算不要）	$O(d) \sim O(d^2)$	不要

✓ RBF カーネルの場合は「無限次元」！

ガウシアン（RBF）カーネル $k(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$ が対応する特徴空間は**無限次元**です。通常の意味での「特徴ベクトルを作る」ことは不可能ですが、カーネルトリックを使えばその内積を有限の計算で求められます。

代表的なカーネル関数

名称	定義式	特徴・用途
線形カーネル	$k(\mathbf{x}, \mathbf{x}') = \mathbf{x}^\top \mathbf{x}'$	通常の内積。カーネルトリックなしと等価。
多項式カーネル	$k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^\top \mathbf{x}' + c)^p$	次数 p の相互作用を捉える。 $c \geq 0$ 。
RBF / ガウシアン	$k(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{\ \mathbf{x} - \mathbf{x}'\ ^2}{2\sigma^2}\right)$	無限次元特徴空間。最も汎用的。局所的類似度を測る。
シグモイドカーネル	$k(\mathbf{x}, \mathbf{x}') = \tanh(\alpha \mathbf{x}^\top \mathbf{x}' + c)$	ニューラルネットの活性化関数に類似。条件付きで PSD。
Laplace カーネル	$k(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{\ \mathbf{x} - \mathbf{x}'\ _1}{\sigma}\right)$	L1 ノルムを使うため外れ値に頑健。



SVM へのカーネルトリック適用

ハードマージン SVM の主問題（復習）

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{s.t.} \quad y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1 \quad \forall i$$

双対問題 (Dual) への変換

ラグランジュ乗数 $\alpha_i \geq 0$ を導入し、KKT 条件を用いると 次の**双対問題**が得られます。

双対問題 (DUAL)

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \underbrace{\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)}_{=k(\mathbf{x}_i, \mathbf{x}_j)} \quad \text{s.t.} \quad \alpha_i \geq 0, \sum_i \alpha_i y_i = 0$$

$\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$ を $k(\mathbf{x}_i, \mathbf{x}_j)$ に置き換えれば完成！

予測時の決定関数

決定関数

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i \in \text{SV}} \alpha_i y_i k(\mathbf{x}_i, \mathbf{x}) + b \right)$$

サポートベクトル (SV) のみが寄与。 $\phi(\mathbf{x})$ は一切計算不要。

✓ カーネル SVM の流れ

- 1 グラム行列 $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ を計算 ($O(n^2 d)$)。
- 2 双対問題の二次計画 (QP) を $\boldsymbol{\alpha}$ について解く。
- 3 サポートベクトルを特定し、バイアス b を求める。
- 4 新規データ $\mathbf{x}$ に対し $k(\mathbf{x}_i, \mathbf{x})$ を計算して予測。

SECTION 07

カーネル k-means：重心からの距離をカーネルで計算する

カーネルトリックはSVMだけのものではありません。k-meansにおける**重心からの距離の計算**も、カーネルだけで表現できます。これが「カーネルの枠組みの力」を示す良い例です。

通常の k-means の距離計算

クラスタ C_k の重心を $\boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{j \in C_k} \mathbf{x}_j$ とすると、点 $\mathbf{x}_i$ から重心までの距離の2乗は：

$$\|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 = \|\mathbf{x}_i\|^2 - \frac{2}{|C_k|} \sum_{j \in C_k} \mathbf{x}_i^\top \mathbf{x}_j + \frac{1}{|C_k|^2} \sum_{j, l \in C_k} \mathbf{x}_j^\top \mathbf{x}_l$$

特徴空間での重心距離

特徴空間に写像した後の重心は $\boldsymbol{\mu}_k^\phi = \frac{1}{|C_k|} \sum_{j \in C_k} \phi(\mathbf{x}_j)$ 。その距離の2乗は：

特徴空間における距離²（展開）

$$\begin{aligned} \|\phi(\mathbf{x}_i) - \boldsymbol{\mu}_k^\phi\|^2 &= \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_i) \rangle - \frac{2}{|C_k|} \sum_{j \in C_k} \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle \\ &\quad + \frac{1}{|C_k|^2} \sum_{j, l \in C_k} \langle \phi(\mathbf{x}_j), \phi(\mathbf{x}_l) \rangle \\ &= k(\mathbf{x}_i, \mathbf{x}_i) - \frac{2}{|C_k|} \sum_{j \in C_k} k(\mathbf{x}_i, \mathbf{x}_j) \\ &\quad + \frac{1}{|C_k|^2} \sum_{j, l \in C_k} k(\mathbf{x}_j, \mathbf{x}_l) \end{aligned}$$

🔑 重心を陽に計算しなくてよい

$\phi(\mathbf{x}_i)$ も $\boldsymbol{\mu}_k^\phi$ も計算不要。必要なのはカーネル値 $k(\mathbf{x}_i, \mathbf{x}_j)$ だけです。グラム行列さえあれば、すべての距離計算はその行列の演算で完結します。

カーネル k-means アルゴリズム

✓ アルゴリズムの手順

- 1 グラム行列 $K \in \mathbb{R}^{n \times n}$ 、 $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ を計算。
- 2 各点のクラスタ割り当て $c_i \in \{1, \dots, K\}$ を初期化。
- 3 （割り当てステップ）各 i について、上式の距離が最小のクラスタに再割り当て。

Python での実装例（スケッチ）

```
import numpy as np

def rbf_kernel(X, gamma=1.0):
    # グラム行列を計算
    sq_dists = np.sum(X**2, axis=1, keepdims=True) \
        + np.sum(X**2, axis=1) \
        - 2 * X @ X.T
    return np.exp(-gamma * sq_dists)

def kernel_kmeans(K, n_clusters, n_iter=100):
    n = K.shape[0]
    labels = np.random.randint(0, n_clusters, n)

    for _ in range(n_iter):
        # クラスタごとの距離2を計算
        dist = np.zeros((n, n_clusters))
        for k in range(n_clusters):
            mask = (labels == k)
            nk = mask.sum()
            if nk == 0:
                continue
            # 3つの項を計算
            term1 = np.diag(K)
            term2 = 2 / nk * K[:, mask].sum(axis=1)
            term3 = 1 / nk**2 * K[np.ix_(mask, mask)].sum()
            dist[:, k] = term1 - term2 + term3

        new_labels = dist.argmin(axis=1)
        if np.all(new_labels == labels):
            break
        labels = new_labels

    return labels
```

⚠ カーネル K-MEANS の注意点

通常の k-means と異なり、特徴空間の重心を元空間に引き戻して可視化することはできません。また、新規データ点の割り当ては訓練データとのカーネル値が必要です。計算コストはグラム行列の保存・利用に $O(n^2)$ かかります。

非線形クラスタリングへの効果




図4：同心円状のデータは通常 k-means では分離できないが、カーネル k-means なら可能

SECTION 08

まとめ

🔑 本日のキーマッセージ

- 特徴写像 ϕ** はデータを高次元（場合によっては無限次元）の特徴空間に写す。これにより線形モデルが非線形パターンを捉えられる。
- カーネル関数 k** は特徴空間内の内積を、元空間の計算だけで求める。PSD 対称関数であれば有効なカーネル（Mercer の定理）。
- カーネルトリック** ：アルゴリズムの k で置き換えると、特徴ベクトルの陽な計算なしに高次元の恩恵が得られる。
- SVM** への適用：双対問題が内積のみで書けるため、カーネルトリックが完全に適用できる。
- カーネル k-means** ：重心からの距離²も内積の組み合わせで書けるため、グラム行列だけで非線形クラスタリングが実現する。

カーネルトリックが適用できる主なアルゴリズム

アルゴリズム	カーネル版の名称	鍵となる内積の役割
SVM	Kernel SVM	双対問題の $\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$
PCA	Kernel PCA	共分散行列の固有分解 → グラム行列の固有分解
k-means	Kernel k-means	重心距離の展開

アルゴリズム	カーネル版の名称	鍵となる内積の役割
Ridge 回帰	Kernel Ridge Regression	正規方程式のカーネル化
Fisher 判別	Kernel FDA	散布行列のカーネル化

「内積さえ計算できれば、高次元の幾何学が使える」
——カーネルトリックはその普遍的な原理を形にしたもの