

ROC曲線と Precision-Recall曲線

予測スコアの降順ソートという視点から、二つの曲線が「描かれる仕組み」を丁寧に解説します。

前提設定：サンプルと予測スコア

二値分類モデルは、各サンプルに対して「正例らしさ」を表す 予測スコア（確率） を出力します。評価の本質は、「このスコアで正例と負例をどれだけ分離できているか」を測ることです。

● 正例（Positive） $y = 1$

● 負例（Negative） $y = 0$

■ 予測スコア $\hat{p} \in [0, 1]$

以下では 正例 5件・負例 5件、計10件 の例を使います。スコアの 降順（高い順） に並べると次のようになります。

順位	スコア $\hat{p}$	真のラベル	TP累計	FP累計
1	0.92	Positive	1	0
2	0.85	Positive	2	0
3	0.72	Negative	2	1
4	0.68	Positive	3	1
5	0.55	Negative	3	2
6	0.47	Positive	4	2
7	0.38	Negative	4	3
8	0.27	Negative	4	4
9	0.18	Positive	5	4
10	0.08	Negative	5	5

上から順に「閾値をここに置いたら」と想像してください。

順位 k のサンプルまでを「陽性と判定」したとき、**TP累計** = 正例を何件拾えたか、**FP累計** = 負例を何件誤って拾ったか、です。

全体の正例数 $P = 5$ 、負例数 $N = 5$ です。

ROC曲線（Receiver Operating Characteristic）

ROC曲線は、偽陽性率（FPR）を横軸、真陽性率（TPR）を縦軸 にとった曲線です。「閾値を下げるほど（＝リストの下まで陽性と判定するほど） どちらも増える」という関係を視覚化します。

TPR（感度・再現率）

TPR = TP / P = TP / 5

FPR（1 - 特異度）

FPR = FP / N = FP / 5

各閾値での (FPR, TPR) を追う


スタートは (0, 0)（誰も陽性と判定しない）、ゴールは (1, 1)（全員を陽性と判定する）です。

降順リストを1件ずつ「陽性」に加えるたびに、*正例*ならTPRが上昇、*負例*ならFPRが右進します。

開始 —	全サンプルを「陰性」と判定。TP=0, FP=0	ROC点 (0.00, 0.00)
順位1 0.92	Positive を追加 → TP=1, FP=0 → TPRが上昇	ROC点 (0.00, 0.20)
順位2 0.85	Positive を追加 → TP=2, FP=0 → TPRが上昇	ROC点 (0.00, 0.40)
順位3 0.72	Negative を追加 → TP=2, FP=1 → FPRが右進	ROC点 (0.20, 0.40)
順位4 0.68	Positive を追加 → TP=3, FP=1 → TPRが上昇	ROC点 (0.20, 0.60)
順位5 0.55	Negative を追加 → TP=3, FP=2 → FPRが右進	ROC点 (0.40, 0.60)
順位6 0.47	Positive を追加 → TP=4, FP=2 → TPRが上昇	ROC点 (0.40, 0.80)
順位7 0.38	Negative を追加 → TP=4, FP=3 → FPRが右進	ROC点 (0.60, 0.80)
順位8 0.27	Negative を追加 → TP=4, FP=4 → FPRが右進	ROC点 (0.80, 0.80)
順位9 0.18	Positive を追加 → TP=5, FP=4 → TPRが上昇	ROC点 (0.80, 1.00)

順位10	Negative を追加 → TP=5, FP=5 → FPRが右進	ROC点 (1.00, 1.00)
0.08		

ROCの形の直感：正例が上位に集まっているほど、曲線は「左上」に凸になります。完全ランダムな分類器は対角線（FPR = TPR）、完全な分類器は左上の角を通ります。



ROCの読み方まとめ

- ・ 正例を拾うとき → 点が **上へ** 動く（TPRが増加）
- ・ 負例を誤って拾うとき → 点が **右へ** 動く（FPRが増加）
- ・ 理想的なモデルは左上の角（0, 1）を通る折れ線に近づく
- ・ AUC（曲線下面積）は 0.5（ランダム）～ 1.0（完全）の範囲をとる

0.84

AUC-ROC（この例）
ランダムに選んだ正例のスコアが
負例より高い確率と等しい

0.50

AUC-ROC（ランダム分類器）
正例・負例の区別がつかない
対角線に一致


1.00

AUC-ROC（完全分類器）
全正例が全負例より
上位にランクされる

Precision-Recall曲線（PR曲線）

PR曲線は、Recallを横軸、Precisionを縦軸 にとった曲線です。ROC曲線と同様に閾値を動かすことで描かれていますが、両指標とも「予測陽性の中での話」または「全正例の中での話」であり、**クラス不均衡に敏感な指標**です。

PRECISION（適合率）	RECALL（再現率 = TPR）
$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$	$\text{Recall} = \frac{\text{TP}}{\text{P}} = \frac{\text{TP}}{5}$



PR曲線の読み方まとめ

- ・ 正例を拾うとき → Recallが増加、Precisionはやや **回復** する傾向
- ・ 負例を誤って拾うとき → Recallは変わらず、Precisionが **低下**
- ・ 終点のPrecisionは $P/(P+N)$ （正例の割合）に収束
- ・ AP（Average Precision）≒ 曲線下面積。クラス不均衡時はROC-AUCより厳しい評価になる

ROC曲線とPR曲線の使い分け

観点	ROC曲線 / AUC-ROC	PR曲線 / AP
横軸	FPR = FP / N（負例中の誤り率）	Recall = TP / P（正例の回収率）
縦軸	TPR = TP / P（正例の回収率）	Precision = TP / (TP+FP)（陽性判定の精度）
分母に含む量	N（負例数）が両軸に関わる	NはFP経由でPrecisionにのみ影響
クラス不均衡時	Nが大きくてもFPRは小さく見えやすく、 楽観的な評価 になりがち	負例が多いとPrecisionが厳しく下がるため、より 現実的な評価
適した場面	クラスバランスが取れている場合、モデルの総合的なランキング能力の比較	正例が少ない場合（不正検知、希少疾患検出など）
ベースライン	AUC = 0.5（対角線）がランダム	Precision = P/(P+N)の水平線がランダム

共通の本質：どちらの曲線も「降順ソートされたリストを上から走査する」という同じ操作から生まれます。違いは **何を軸にと**るかだけです。ROCは「**正例**と**負例**それぞれの中での割合」を追い、PRは「**正例**の中での割合」と「**陽性判定全体の中での正例割合**」を追います。